

**NLP**

# Named Entity Recognition

# NER做什么

国务院 总理 李克强 调研 上海 外高桥 时 提出 , 支持 上海 积极 探索 新 机制 。

机构 人名 地名 地名

中国 银行 西藏 自治区 分行 行长 索朗达吉

B-ORG I-ORG B-GPE O O O B-PER

- NER标注一般采用如下标注形式
  - O 非实体
  - S 单独构成实体
  - B 为实体的开始
  - I 为实体的中间
  - E 为实体的结尾

# NER的发展

- 基于词典和规则的方法 [略]
- 传统机器学习
  - 无监督学习
  - CRF
- Emb[NN/Attention]-NN-CRF/LSTM [重点]
- 少量标注的训练集的研究 [重点]
  - 半监督学习
  - 主动学习
  - 对抗生成网络
  - 迁移学习
- 主要的问题[研究热点]
  - 标注集少
  - 标注结果准确率与成本的平衡

# 无监督学习[1][13]

- 不用标注数据，按数据的相似度聚类

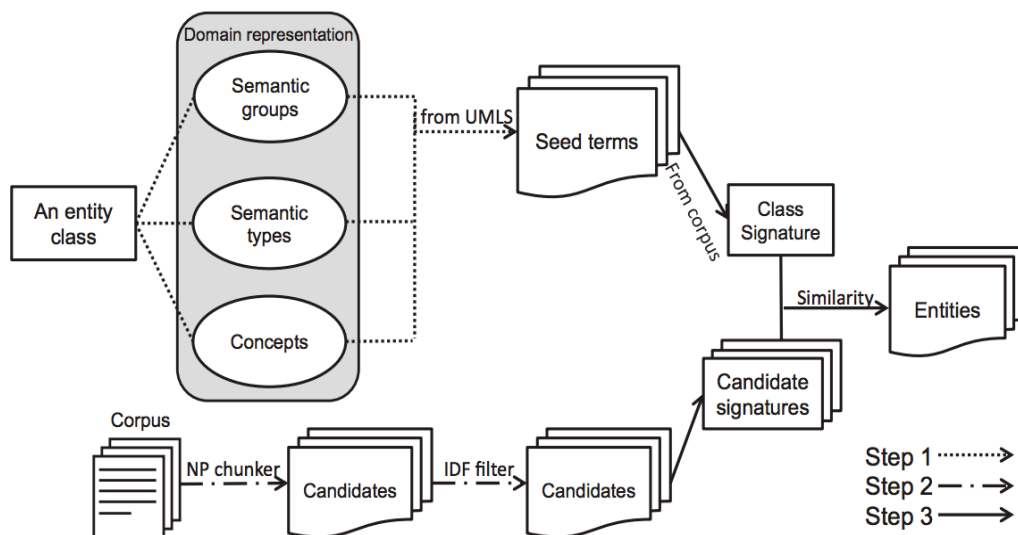


Fig. 1. Overall approach to unsupervised biomedical named entity recognition.

## Step 1: Seed term collection

通过对实体类的语义组，类型，概念从UMLS中获取相关类的术语实体作为种子术语。

## Step 2: Boundary detection

对Corpus进行分块，获取名词短语，使用IDF过滤

$$IDF(t, D) = \log(|D| / |d \in D : t \in d|)$$

## Step 3: Entity classification

构建词表大小V (all possible unigrams)

t[step1和step2中的结果]用特征维度为2V的 $s^t$ 表示:

$$s^t = \langle s_1^t, s_2^t, \dots, s_V^t, s_{V+1}^t, \dots, s_{2V}^t \rangle \quad (2)$$

Values in the vector are calculated as follows:


$$s_i^t = w_i * f(v_i, t) * IDF(v_i, D), \quad i = 1 \dots V \quad (3)$$

$$s_i^t = w_o * f(v_i, context_t) * IDF(v_i, D), \quad i = V + 1 \dots 2V \quad (4)$$

类别特征按类取平均，候选特征和类别特征用余弦相似度聚类  
改进：可以使用K-means继续优化

# CRF

- 观测序列X[未标记序列]和状态序列Y[标记序列]
- 转移概率:  $Y_i \rightarrow Y_{i+1}$  , 状态概率:  $X \rightarrow Y_i$
- CRF: 训练集中寻找实体上下文的模板, 测试集中将上下文和模板匹配的中间词作为对应实体标注



$$P(y|x) = \frac{1}{Z(x)} \exp \left( \sum_{i,k} \lambda_k t_k(y_{i-1}, y_i, x, i) + \sum_{i,l} \mu_l s_l(y_i, x, i) \right)$$

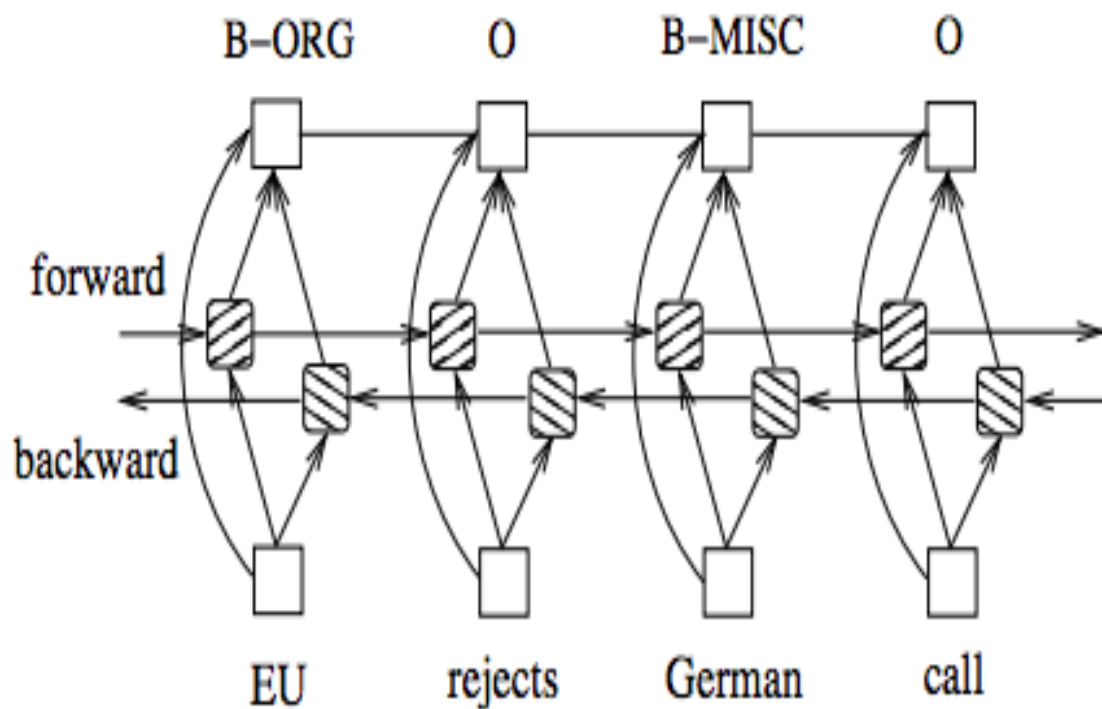
$$Z(x) = \sum_y \exp \left( \sum_{i,k} \lambda_k t_k(y_{i-1}, y_i, x, i) + \sum_{i,l} \mu_l s_l(y_i, x, i) \right)$$

```
features = [  
    'bias',  
    'word='+word,  
    # 'word.lower='+ word.lower(),  
    # 'word[-3:]='+ word[-3:],  
    # 'word[-2:]='+ word[-2:],  
    # 'word.isupper='+ word.isupper(),  
    # 'word.istitle='+ word.istitle(),  
    'word.isdigit='+ word.isdigit(),  
    'postag=' + postag,  
    'cuttag=' + cuttag,  
    # 'postag[:2]='+ postag[:2],  
]  
if i > 0:  
    word1 = sent[i - 1][0]  
    postag1 = sent[i - 1][2]  
    cuttag1 = sent[i - 1][1]  
    features.extend([  
        '-1:word='+word1,  
        '-1:postag=' + postag1,  
        '-1:cuttag=' + cuttag1,  
        # '-1:postag[:2]='+ postag1[:2],  
    ])  
else:  
    features.append('BOS')  
  
if i < len(sent) - 1:  
    word1 = sent[i + 1][0]  
    postag1 = sent[i + 1][2]  
    cuttag1 = sent[i + 1][1]  
    features.extend([  
        '+1:word=' + word1,  
        '+1:postag=' + postag1,  
        '+1:cuttag=' + cuttag1,  
    ])
```

一般的CRF线性链如左图所示, 中间的图是实际中使用CRF进行NER的特征提取代码, 比如要预测 $Y_i$ , word为 $X_i$ , 可以看到除了对 $X_i$ 提取特征外, 还涉及到了 $X_i$ 前面的一个词和后面一个词。

但是并没有将全部的上下文考虑进去, 这是CRF问题, 后面的NN结构解决了该问题

# Emb-BiLSTM-CRF[3][15]

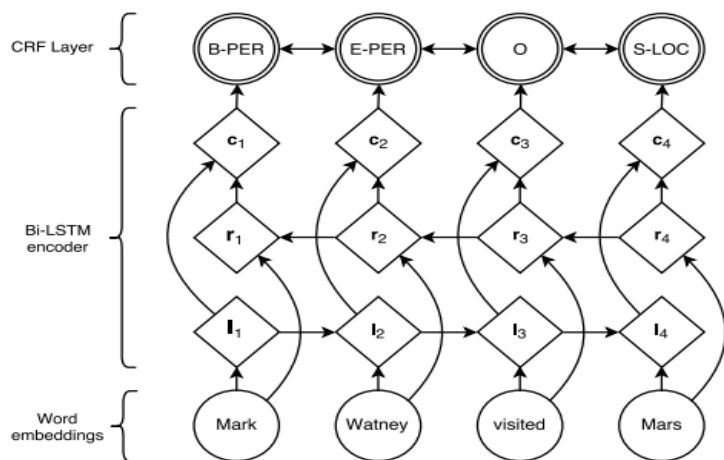


Embedding: 使用前置训练,  
130K Vocabulary, 50 维

直接将BiLSTM的输出传给CRF层

CRF层的输入: 手工添加了很多  
特征, 比如spelling, context等特征

# Emb[LSTM]-BiLSTM-CRF[5][16]



句子的长度为  $n$ ，不同的标记个数为  $k$ ，将 Bi-LSTM 输出（要经过 softmax 层，变成  $k$  维的向量）作为打分矩阵  $P$ ，

即  $P_{i,j}$  表示句子的第  $i$  个单词对应的是第  $j$  个标签的分数

$$X = (x_1, x_2, \dots, x_n)$$

$$y = (y_1, y_2, \dots, y_n)$$

$$s(X, y) = \sum_{i=0}^n A_{y_i, y_{i+1}} + \sum_{i=1}^n P_{i, y_i}$$

$A$  表示的是转移分数， $A_{i,j}$  表示从第  $i$  个标记转到第  $j$  个标记的分数

softmax:

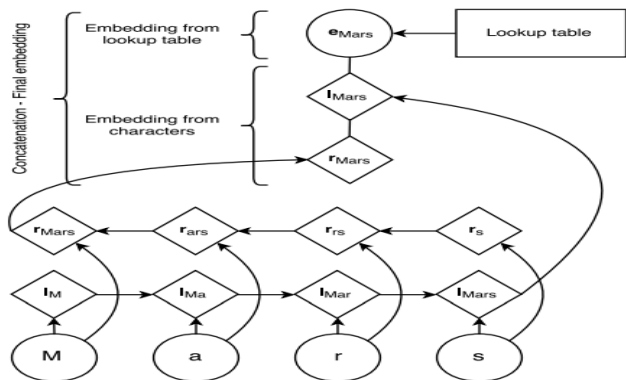
$$p(y|X) = \frac{e^{s(X,y)}}{\sum_{y'} e^{s(X,y')}}$$

log 最大似然进行训练:

$$\log(p(y|X)) = s(X, y) - \log \left( \sum_{y'} e^{s(X, y')} \right)$$

动态规划来预测:

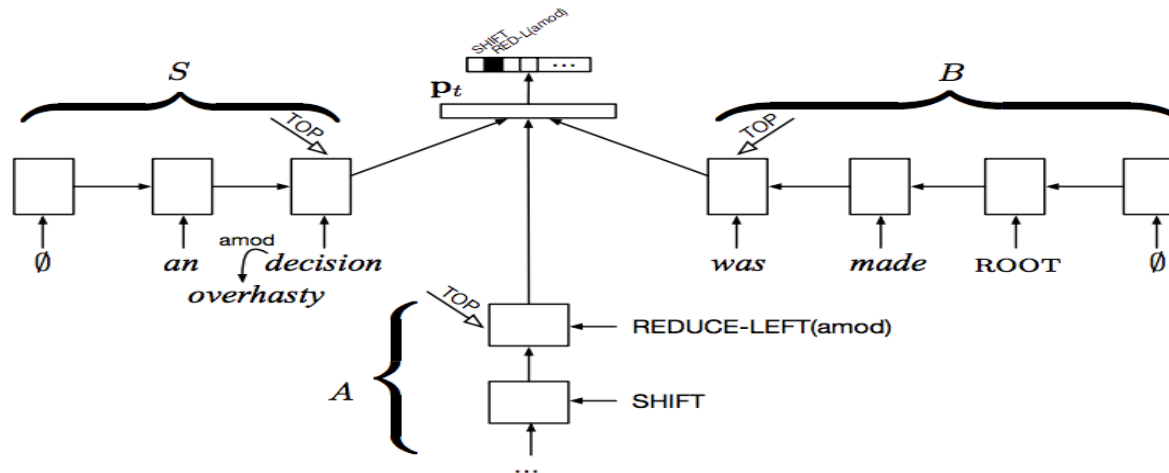
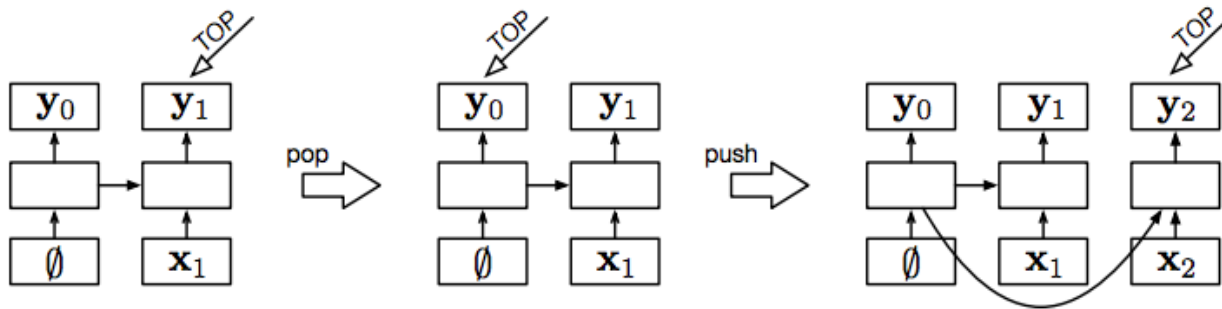
$$y^* = \arg \max_{y \in Y_x} s(X, y)$$



[Guillaume Lample et al.2016] Neural Architectures for Named Entity Recognition



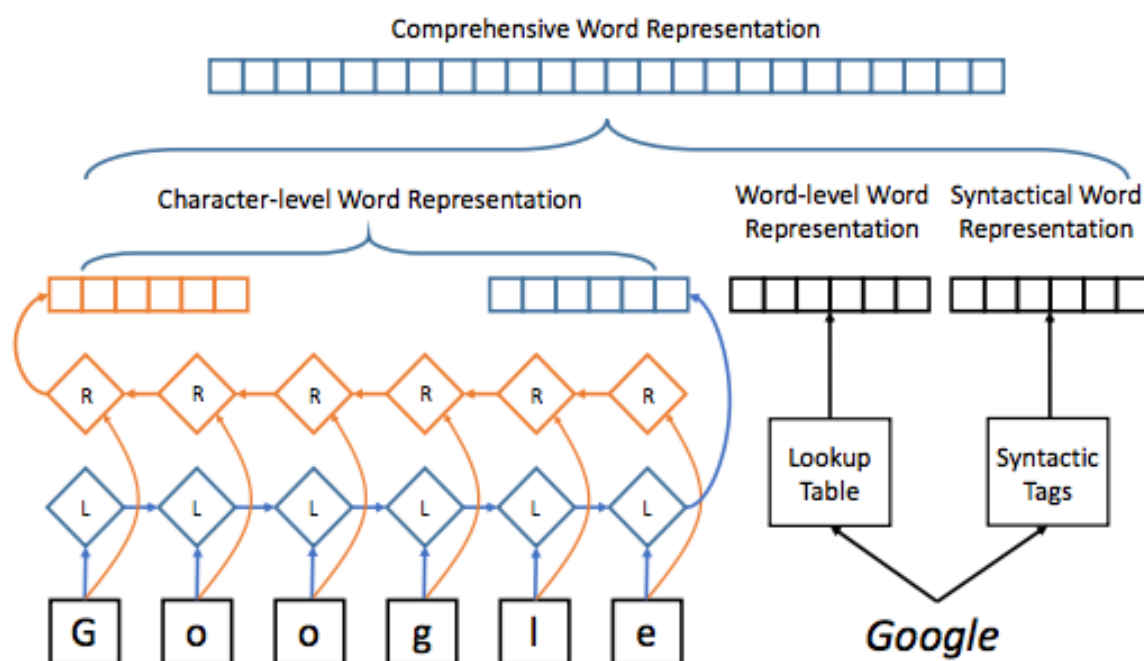
# Stack-LSTM[5][16]



[Guillaume Lample et al.2016] Neural Architectures for Named Entity Recognition

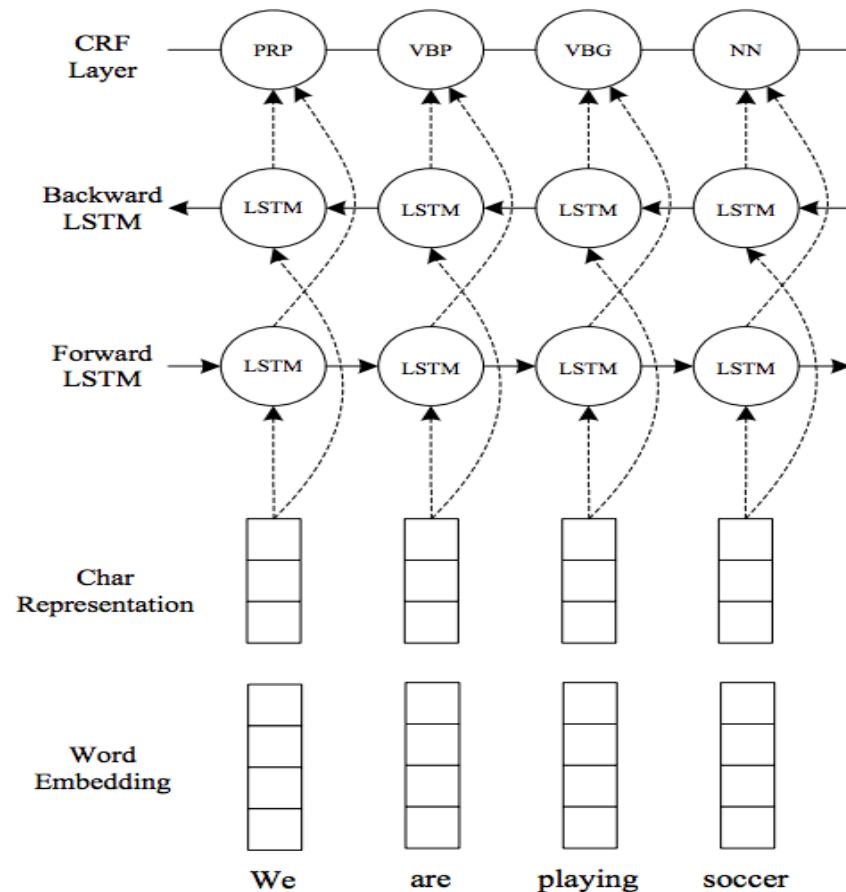

[Chris Dyer et al.2015] Transition-Based Dependency Parsing with Stack Long Short-Term Memory

# Multi-channel-BiLSTM-CRF[15][17]



主要是嵌入层的改变，如左图，除了加入字符嵌入，词嵌入外，还加入了词性，句法，语义等信息。

# Emb[CNN]-BiLSTM-CRF[6][16]



[Xuezhe Ma et al.2016] End-to-end Sequence Labeling via Bi-directional LSTM-CNNs-CRF

# Emb[Attention]+BiLSTM+CRF[7][16]

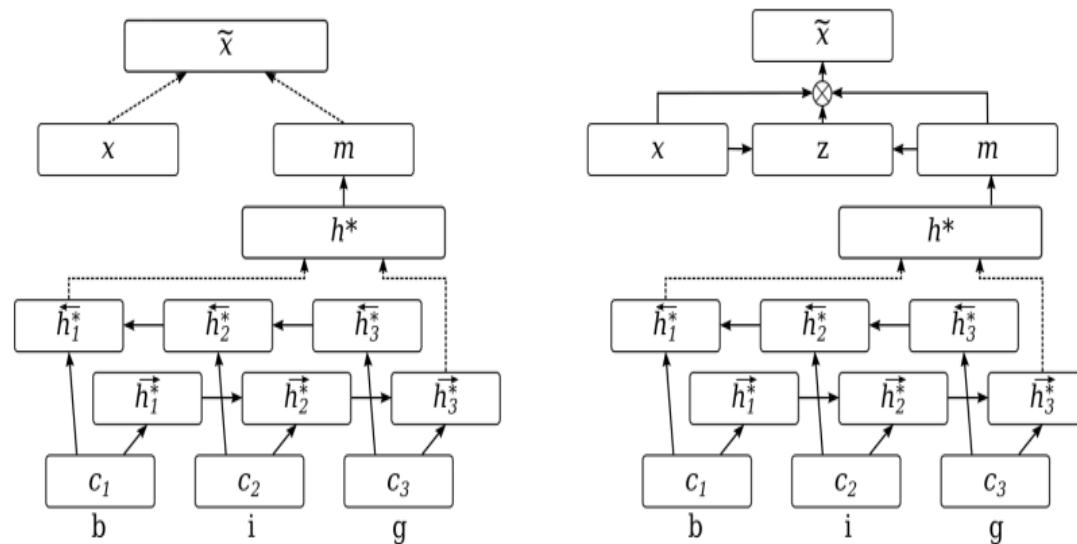


Figure 2: Left: concatenation-based character architecture. Right: attention-based character architecture. The dotted lines indicate vector concatenation.

$$z = \sigma(W_z^{(3)} \tanh(W_z^{(1)} x + W_z^{(2)} m)) \quad \tilde{x} = z \cdot x + (1 - z) \cdot m$$

# Emb[LSTM]-BiLSTM-CRF[10][16]

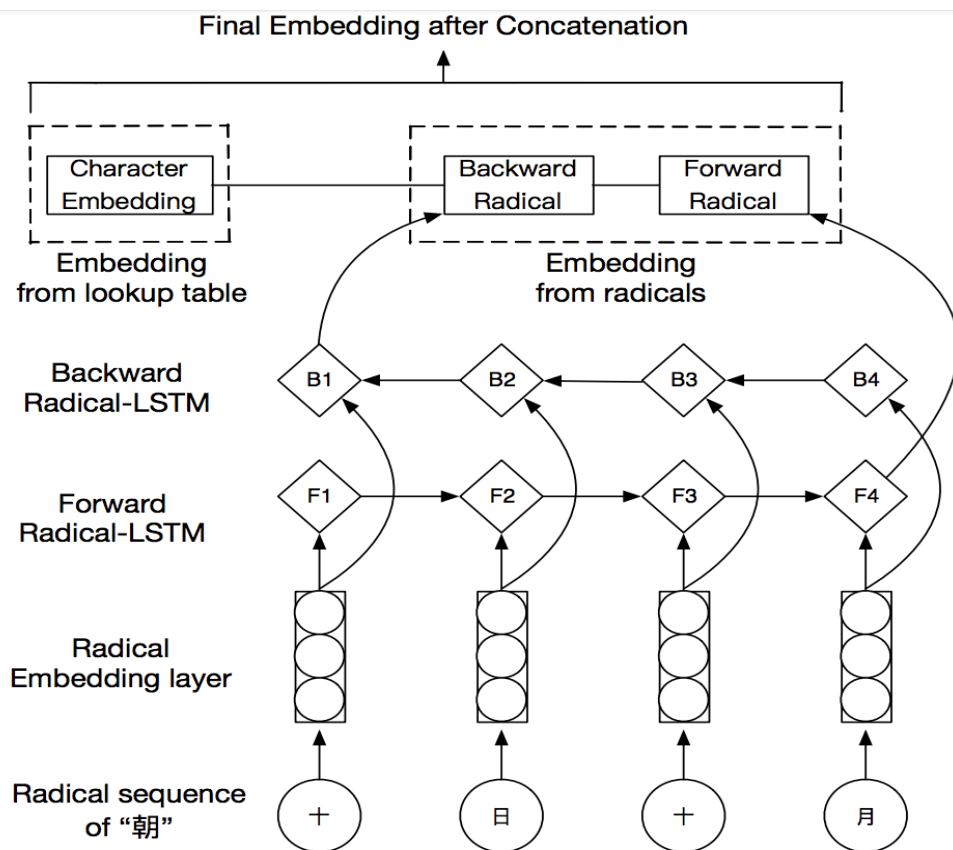


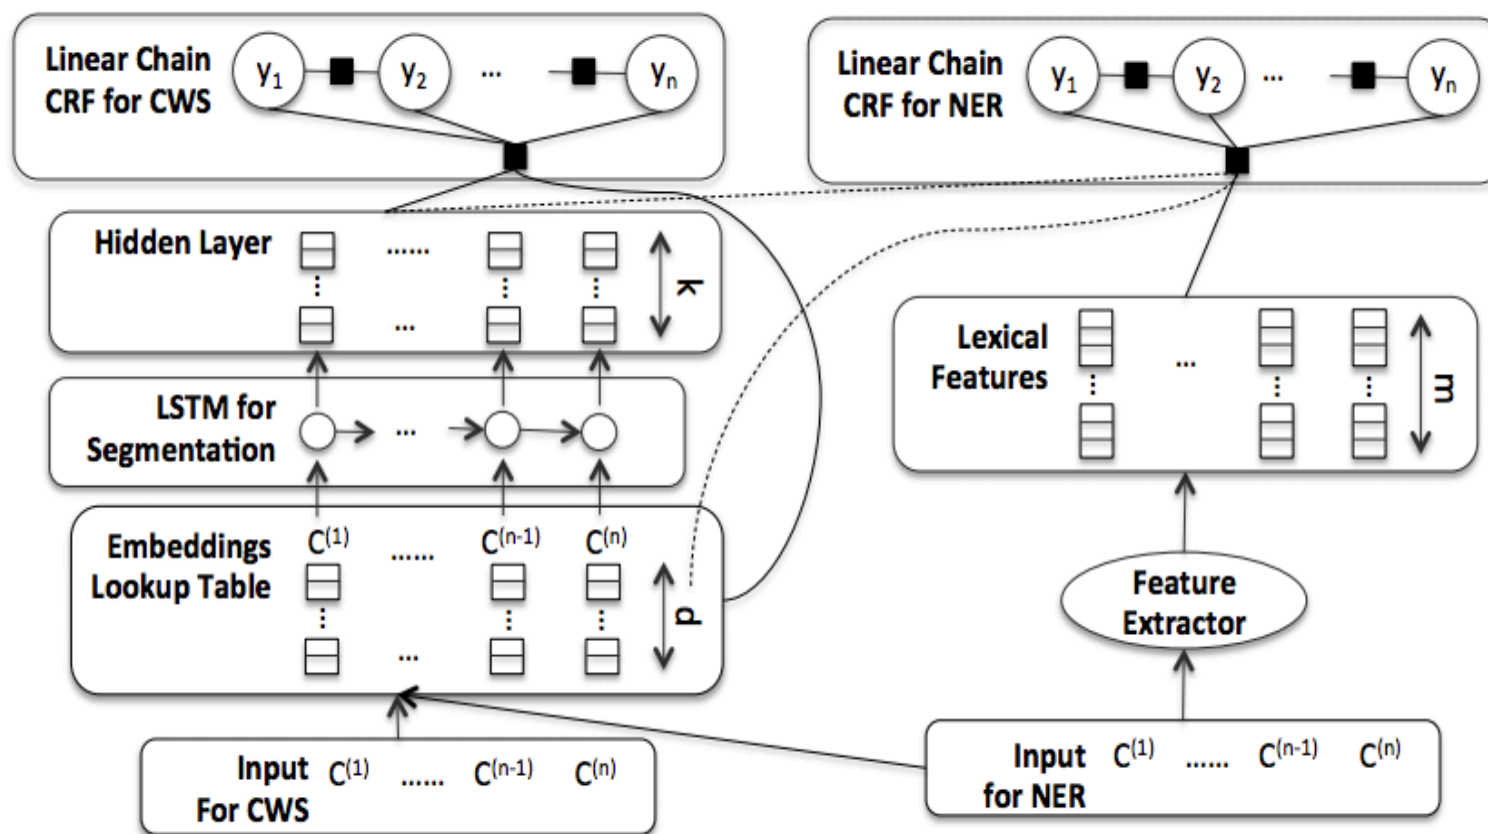
Table 3: Results with different components.

Variant	F1
random + dropout	88.91
random + radical + dropout	89.44
pretrain + dropout	90.75
pretrain	86.87

Model	PER-F	LOC-F	ORG-F	P	R	F
Zhou2006	90.09	85.45	83.10	88.94	84.20	86.51
Chen2006	82.57	90.53	81.96	91.22	81.71	86.20
Zhou2013	90.69	91.90	86.19	91.86	88.75	90.28
Zhang2006*	96.04	90.34	85.90	92.20	90.18	<b>91.18</b>
BLSTM-CRF + radical	89.62	91.76	85.79	91.39	88.22	89.78
BLSTM-CRF + pretrain	91.77	<b>92.10</b>	<b>87.30</b>	91.28	<b>90.62</b>	<b>90.95</b>

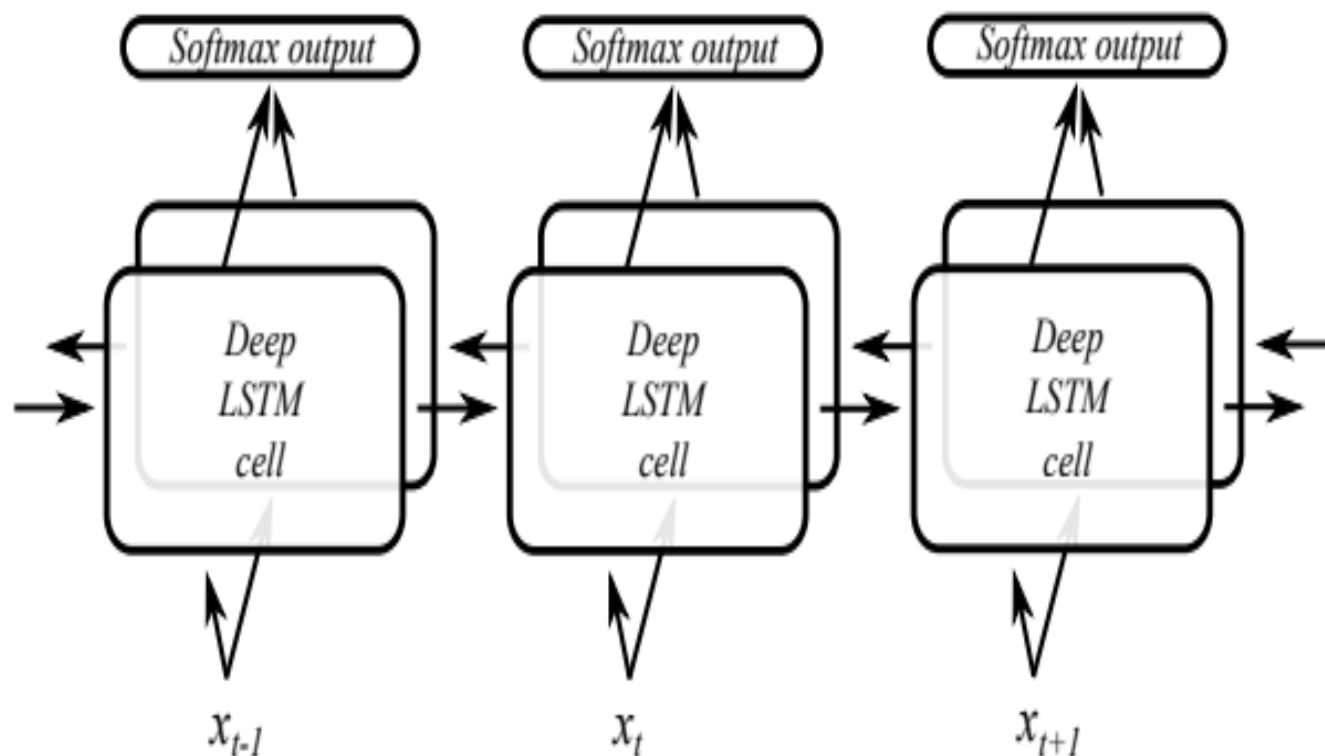
[Chuanhai Dong et al.2016] Character-Based LSTM-CRF with Radical-Level Features for Chinese Named Entity Recognition

# With Word Segmentation[8][16]



[Nanyun Peng et al.2016] Improving Named Entity Recognition for Chinese Social Media with Word Segmentation Representation Learning

# Emb[Character]-DBi-LSTM-Softmax[9][16]



这篇paper中发现以下三种实体：

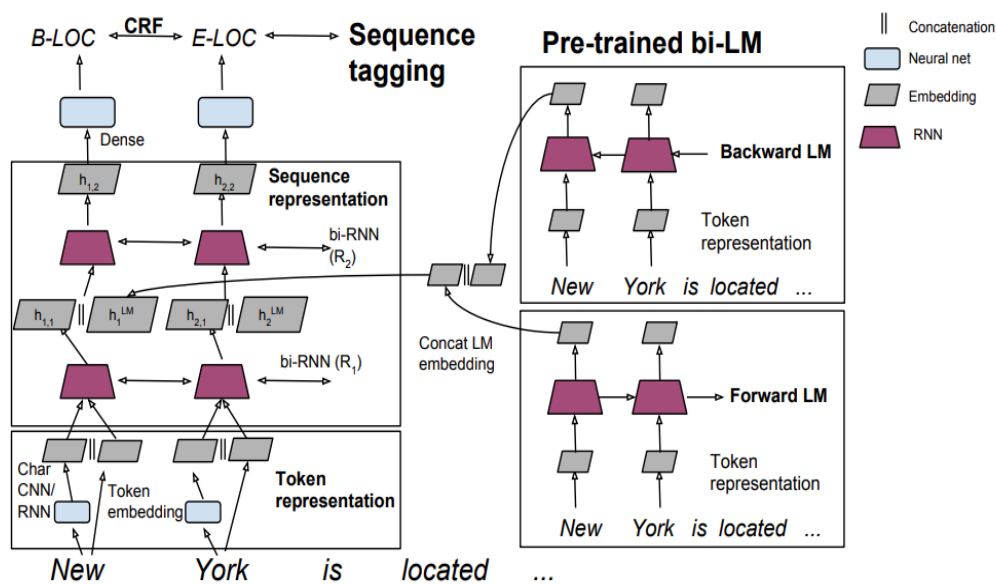
disorders and findings[疾病 and ...]

pharmaceutical drugs[药物]

body structure[身体结果]

# Semi-supervised sequence tagging[11][17]

- 利用无标签数据来优化有标签数据训练的模型



Model	$F_1 \pm \text{std}$
Chiu and Nichols (2016)	$90.91 \pm 0.20$
Lample et al. (2016)	90.94
Ma and Hovy (2016)	91.37
Our baseline without LM	$90.87 \pm 0.13$
TagLM	<b><math>91.93 \pm 0.19</math></b>


Table 1: Test set  $F_1$  comparison on CoNLL 2003 NER task, using only CoNLL 2003 data and unlabeled text.

左边是NER的三层结构，中间层使用了两层BiLSTM  
右边使用语言模型(前面词预测下一个词)训练词的上下文向量[语料是未标记的数据]



# Emb-IDCNN-CRF[12][17]

- 从CNN和RNN对句子特征提取方面出发，使用迭代扩张卷积替换BiLSTM层



窗口大小为3，4层扩张CNN

本文将block定义为上面的一个结构，将这些block进行堆叠意为迭代

GPU资源匮乏，CNN在并行上的优势[特征独立]

CNN固定窗口大小无法获取更多上下文信息，不断增加CNN虽然可以扩大窗口，但参数增多，分辨表现差

ID-CNN不会损失分辨率，限定参数

Bi-LSTM-CRF (re-impl)  $90.43 \pm 0.12$

ID-CNN-CRF  **$90.54 \pm 0.18$**

Model	Speed
Bi-LSTM-CRF	1×
Bi-LSTM	9.92×
ID-CNN-CRF	1.28×
5-layer CNN	12.38×
ID-CNN	14.10×

# Active Learning - CRF in clinical text[2][15]

- 主动学习分为以下几个部分：
  - 1.初始模型生成：使用少量带标签的样本来构建模型，样本的采样可以使用下面两种方法：一种是随机采样，一种是使用最长句子采样
  - 2.查询：在pool中没有标注的句子使用查询算法被排序，一些算法是使用CRF模型来进行排序，一些不是，选择前N个句子进行注释，然后放到注释过的集合中，每次迭代的batch size按照8, 16, 32, 64的规律选择。
  - 3.训练：CRF模型在更新的注释集中重新训练
  - 4.迭代：重复2, 3过程，直到达到某个标准停止。
- 查询算法：
  - 基于不确定的查询算法，最不确定的句是最有信息量的句子[高度依赖于模型的质量，比如通过CRF模型来排序句子] [论文中比较的结果是该类算法整体优于下面的算法]
  - 基于多样性的查询算法，通过单词，语义，句法来构建向量，通过各个句子之间的相似度来排序

# Proactive Learning[14][17]

- Active learning

- 假设标记的句子没有错误[乏味/困难导致出错在所难免]
- 句子只拿给专家标注[成本高]

- Proactive learning

- 对于困难的标注问题出现错误不可避免，允许专家出错
- 使用两类注释器(者)，reliable expert 和 fallible expert[节约成本]

- Algorithm

1. 在未标记数据集中的所有句子使用active learning 准则排序，最有信息的N个句子作为批次采样的输入，这这一步中，批次的句子分布到两个集合分别给reliable 和fallible。分给fallible的句子是fallible有一个很高概率标记正确的句子，同时，只有那些fallible很难标注的句子才会被送给reliable。这样标记的成本就会减少。

2. 第一步：设定阈值 $\alpha$ ，当fallible expert判别该句子的概率大于这个阈值时，将这个句子分配给fallible expert，否则进到第二步；

第二步：计算句子对reliable和fallible的不同：

$$\begin{aligned} \text{diff}(\text{reliable}, \text{fallible}, \mathbf{x}) \\ = |p(\text{CorrectLabels}|\text{reliable}, \mathbf{x}) \\ - p(\text{CorrectLabels}|\text{fallible}, \mathbf{x})| \quad (4) \end{aligned}$$

设定一个阈值 $\beta$ ，当diff大于该阈值时，将句子交给reliable，否则交给fallible

---

**Algorithm 1: Proactive Learning for NER**

---

**Input:** a labelled dataset  $L$ , an unlabelled dataset  $UL$ , a test dataset  $T$ , a budget  $B$ , a reliable expert  $e_r$  with cost  $C_r$  for each sentence, a fallible expert  $e_f$  with cost  $C_f$ , the current cost  $C$

**Output:** a labelled dataset  $L$

```
1 Estimate the performance of each expert as described in Section 2.1;
2 while  $C < B$  do
3   Train a named entity recognition model  $M$  on  $L$ ;
4   Sort all sentences in the unlabelled dataset according to an active learning criterion;
5   Select the top  $N$  sentences;
6    $UL_r, UL_f =$ 
      $\text{BatchSampling}(M, \text{top } N \text{ sentences})$ ;
7    $L_r, L_f \leftarrow e_r$  and  $e_f$  annotate  $UL_r$  and  $UL_f$  respectively;
8    $L = L \cup L_r \cup L_f$ ;
9    $UL = UL - UL_r - UL_f$ ;
10   $C = C + C_r * |L_r| + C_f * |L_f|$ ;
11 end
```

---

**Algorithm 2: Batch Sampling**

---



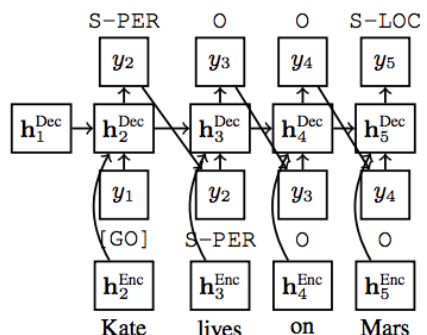
**Input:** a named entity recognition model  $M$ , top- $N$  sentences selected according to an active learning criterion

**Output:**  $UL_r, UL_f$

```
1  $UL_r = \emptyset$ ;
2  $UL_f = \emptyset$ ;
3 while Batch Size do
4   // Stage 1
5   foreach sentence  $\mathbf{x}$  do
6     if  $p(\text{CorrectLabels}|\text{fallible}, \mathbf{x}) > \alpha$  then
7        $UL_f = UL_f \cup \{\mathbf{x}\}$ ;
8       BatchSize = BatchSize - 1;
9     end
10  // Stage 2
11  if Batch Size  $\neq 0$  then
12    Sort the remaining sentences according to a re-ranking criterion;
13    Calculate threshold  $\beta$ ;
14    foreach sentence  $\mathbf{x}$  do
15      if Batch Size  $\neq 0$  then
16        if  $\text{diff}(\text{reliable}, \text{fallible}, \mathbf{x}) < \beta$  then
17           $UL_f = UL_f \cup \{\mathbf{x}\}$ ;
18        else
19           $UL_r = UL_r \cup \{\mathbf{x}\}$ ;
20        end
21      end
22      BatchSize = BatchSize - 1;
23    end
24  end
25 end
```

---

# Deep Active Learning-CNN-CNN-LSTM[16][18]



模型实现加速：使用了CNN-CNN-LSTM模型，这个模型在标准数据集上实现了近乎最先进的效果，同时在计算上比最佳性能的模型更有效[时间和表现综合来说模型最优]

模型在小数据集上表现：在训练过程中执行增量的主动学习，仅仅使用原有训练集的25%，模型就能达到原有的最好表现[节约成本]

嵌入层使用character-level和word-level嵌入级联：

$$\mathbf{w}_i^{\text{full}} := (\mathbf{w}_i^{\text{char}}, \mathbf{w}_i^{\text{emb}}).$$

character-level的嵌入和信息提取层都使用的是CNN层，两层一维卷积+一层最大池化，窗口大小为3

$$\mathbf{h}_i^{\text{Enc}} = (\mathbf{h}_i^{(l)}, \mathbf{w}_i^{\text{full}})$$

解码层使用CRF模块时间复杂度为 $O(nT^2)$ ，而使用LSTM时间复杂度为 $O(nT)$ ，且能达到同样的效果。

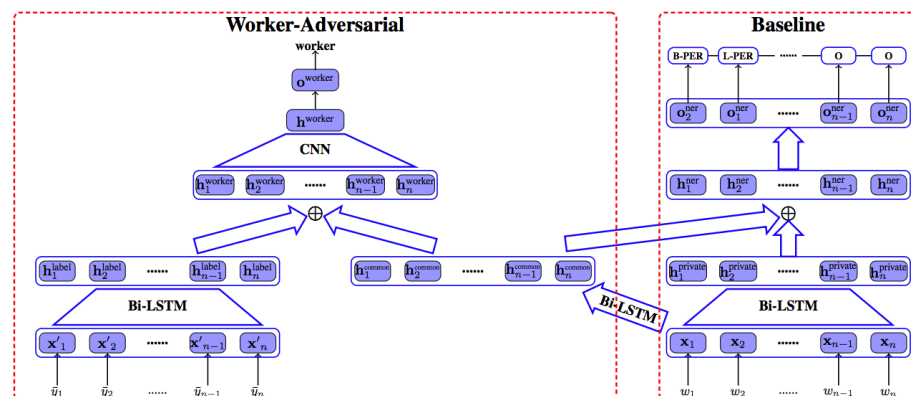
Char	Word	Tag	Reference	F1	Sec/Epoch
None	CNN	CRF	Collobert et al. (2011)	88.67	-
None	LSTM	CRF	Huang et al. (2015)	90.10	-
LSTM	LSTM	CRF	Lample et al. (2016)	90.94	-
CNN	LSTM	CRF	Chiu & Nichols (2016)	90.91 ± 0.20	-
GRU	GRU	CRF	Yang et al. (2016)	90.94	-
None	Dilated CNN	CRF	Strubell et al. (2017)	90.54 ± 0.18	-
LSTM	LSTM	LSTM		90.89 ± 0.19	49
CNN	LSTM	LSTM		90.58 ± 0.28	11
CNN	CNN	LSTM		90.69 ± 0.19	11
CNN	CNN	CRF		90.35 ± 0.24	12

Table 3: Evaluations on the test set of CoNLL-2003 English

[Yanyao Shen et al.2018] DEEP ACTIVE LEARNING FOR NAMED ENTITY RECOGNITION

# Adversarial Learning for Crowd[17][18]

- 从众包标记数据质量低角度出发，通过对抗学习提取公有特征，减轻注释噪声



对抗学习的目的：优化公有模块的学习质量，使之收敛于真实的数据

原有的结构不变(如右部分)，只是加入了对抗网络(左部分)，使用众包标签作为输入，经过Bi-LSTM，和common级联，一维卷积，窗口大小是5，最大池化，最后经过softmax，维度是标注者的个数：

$$\begin{aligned}
 h_t^{\text{worker}} &= h_t^{\text{common}} \oplus h_t^{\text{label}} \\
 \tilde{h}_t^{\text{worker}} &= \tanh(\mathbf{W}^{\text{cnn}}[h_{t-2}^{\text{worker}}, h_{t-1}^{\text{worker}}, \dots, h_{t+2}^{\text{worker}}]) \\
 h^{\text{worker}} &= \text{max-pooling}(\tilde{h}_1^{\text{worker}}, \tilde{h}_2^{\text{worker}}, \dots, \tilde{h}_n^{\text{worker}}) \\
 o^{\text{worker}} &= \mathbf{W}^{\text{worker}} h^{\text{worker}}, \\
 p(\bar{z}|\mathbf{X}, \bar{\mathbf{y}}) &= \frac{\exp(o_z^{\text{worker}})}{\sum_z \exp(o_z^{\text{worker}})},
 \end{aligned}$$

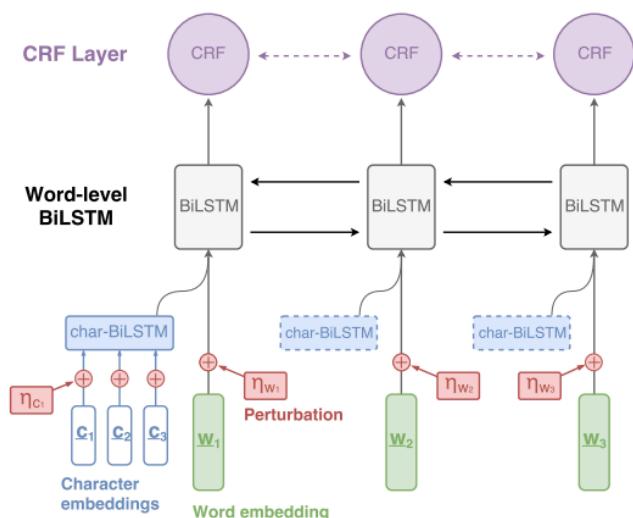
左右联合：

$$\begin{aligned}
 R(\Theta, \Theta', \mathbf{X}, \bar{\mathbf{y}}, \bar{z}) &= \text{loss}(\Theta, \mathbf{X}, \bar{\mathbf{y}}) - \text{loss}(\Theta, \Theta', \mathbf{X}) \\
 &= -\log p(\bar{\mathbf{y}}|\mathbf{X}) + \log p(\bar{z}|\mathbf{X}, \bar{\mathbf{y}}),
 \end{aligned}$$

其中 $\Theta$ 表示整个模型中和NER有关的参数， $\Theta'$ 表示仅仅和worker discriminator有关的参数，其中common Bi-LSTM对应的参数属于 $\Theta$ 中，优化下面式子：

$$\begin{aligned}
 \hat{\Theta} &= \arg \min_{\Theta} R(\Theta, \Theta', \mathbf{X}, \bar{\mathbf{y}}, \bar{z}) \\
 \hat{\Theta}' &= \arg \max_{\Theta'} R(\hat{\Theta}, \Theta', \mathbf{X}, \bar{\mathbf{y}}, \bar{z})
 \end{aligned}$$

# Adversarial Training for Robust[19][18]



在训练词嵌入和字符嵌入的时候加入噪声信息，对于加入噪声的输入，模型仍然需要正确标注出来，提高模型的鲁棒性

输入句子所有的单词/字符嵌入用 $s$ 表示，模型的参数用 $\theta$ 表示， $y$ 为目标的词性标记序列，训练过程中，模型要最小化负对数似然函数：

$$L(\theta; s, y) = -\log p(y | s; \theta)$$

在 $s$ 上加一个连续的扰动向量，这个扰动向量为使得我们的模型的损失函数最大：

$$\eta = \arg \max_{\eta': \|\eta'\|_2 \leq \epsilon} L(\hat{\theta}; s + \eta', y)$$

$\hat{\theta}$ 为模型的参数（在上述求解过程中为常量）对抗训练的样本为：

$$s_{\text{adv}} = s + \eta$$

定义如下对抗训练的损失函数(本文 $\gamma = 0.5$ )：

$$\tilde{L} = \gamma L(\theta; s, y) + (1 - \gamma) L(\theta; s_{\text{adv}}, y)$$

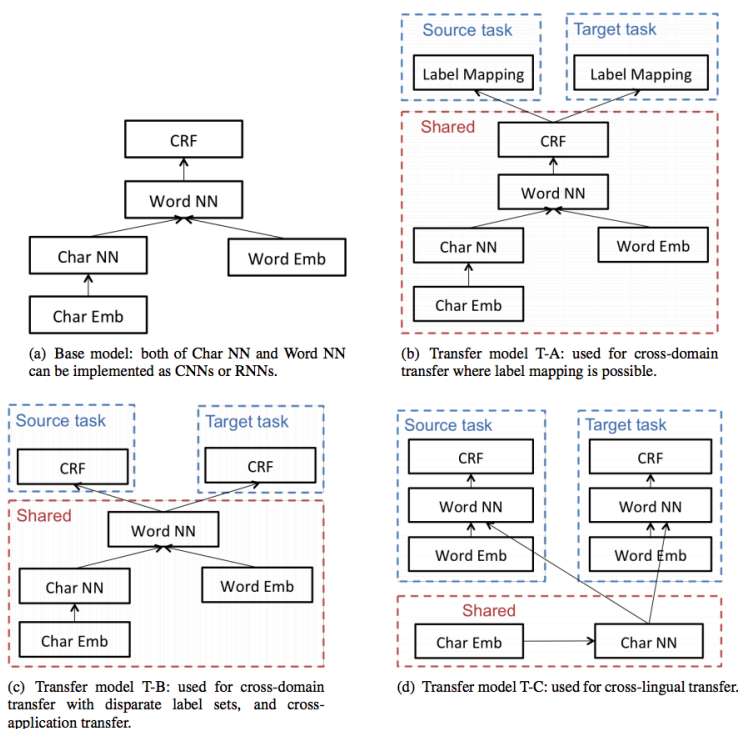
	Our Models		Plank et al. (2016)			Brend (2017)	Nguyen et al. (2017)
	Baseline	Adversarial	BiLSTM	TNT	CRF		
bg	98.34	<b>98.53</b>	97.97	96.84	96.36	95.63	97.4
cs	98.70	<b>98.81</b>	98.24	96.82	96.56	95.83	—
da	96.63	<b>96.74</b>	96.35	94.29	93.83	93.32	95.8
de*	94.29	<b>94.35</b>	93.38	92.64	91.38	90.73	92.7
en	95.72	<b>95.82</b>	95.16	94.55	93.35	93.47	94.7
es	96.26	<b>96.44</b>	95.74	94.55	94.23	94.69	95.9
eu*	94.55	<b>94.71</b>	<b>95.51</b>	93.35	91.63	90.63	93.7
fa	97.38	<b>97.51</b>	97.49	95.98	95.65	96.11	96.8
fr	94.54	<b>95.40</b>	<b>95.85</b>	93.59	90.32	89.19	94.6
hr	96.48	<b>96.63</b>	96.11	94.51	95.14	94.96	96.0
he	97.34	<b>97.43</b>	96.96	93.71	93.63	95.28	—
hi	97.12	<b>97.21</b>	97.10	94.53	96.00	96.09	96.4
hr*	96.12	<b>96.32</b>	<b>96.82</b>	94.06	93.16	93.53	—
id	93.95	<b>94.03</b>	93.41	93.16	92.96	92.02	93.1
it	98.04	<b>98.08</b>	97.95	96.16	96.43	96.28	97.5
nl	92.64	<b>93.09</b>	<b>93.30</b>	88.54	90.03	85.10	91.4
no	97.88	<b>98.08</b>	98.03	96.31	96.21	95.67	97.4
pl*	97.34	<b>97.57</b>	<b>97.62</b>	95.57	93.96	93.95	96.3
pt	97.94	<b>98.07</b>	97.90	96.27	96.32	95.50	97.5
sl*	97.81	<b>98.11</b>	96.84	94.92	94.77	92.70	97.1
sv	96.39	<b>96.70</b>	96.69	95.19	94.45	94.62	—
Avg	96.45	<b>96.65</b>	96.40	94.55	94.11	93.59	95.55
el	98.18	<b>98.24</b>	—	—	—	97.12	—
et*	90.79	<b>91.32</b>	—	—	—	86.30	—
ga	90.66	<b>91.11</b>	—	—	—	88.82	—
hu*	93.39	<b>94.02</b>	—	—	—	89.47	—
ro	91.24	<b>91.46</b>	—	—	—	88.99	—
ta	82.91	<b>83.16</b>	—	—	—	81.80	—
Avg	91.20	<b>91.55</b>	—	—	—	88.41	—

[Michihiro Yasunage et al.2018] Robust Multilingual Part-of-Speech Tagging via Adversarial Training



# Transfer Learning for sequence tagging[13][17]

- 迁移学习通过学习相关领域(source)的知识来提高当前领域(target)模型的性能



该论文中 word-level和character-level部分都使用的是GRU  
其中CRF部分添加了max-margin principle, 如下:

$$f(\mathbf{h}, \mathbf{y}) - \log \sum_{\mathbf{y}' \in \mathcal{Y}(\mathbf{h})} \exp(f(\mathbf{h}, \mathbf{y}') + \text{cost}(\mathbf{y}, \mathbf{y}')),$$

$\mathbf{h}$  为从 word-level 和 character-level 部分学习到的特征表示,  $\mathbf{h} = (h_1, \dots, h_T)$ ,  $\mathbf{y}$  为标记序列,  $\mathbf{y} = (y_1, \dots, y_T)$ , 其中  $\mathcal{Y}(\mathbf{h})$  表示  $\mathbf{h}$  对应的标记空间,  $\text{cost}$  函数表示当  $\mathbf{y}'$  和  $\mathbf{y}$  的差距越大, 惩罚越大。  $f$  函数表示的是 CRF 中的打分函数, 前面提到的  $s(\mathbf{X}, \mathbf{y})$ 。

Table 3: Comparison with state-of-the-art results (%).

Model	CoNLL 2000	CoNLL 2003	Spanish	Dutch	PTB 2003
Collobert et al. (2011)	94.32	89.59	—	—	97.29
Passos et al. (2014)	—	90.90	—	—	—
Luo et al. (2015)	—	91.2	—	—	—
Huang et al. (2015)	94.46	90.10	—	—	97.55
Gillick et al. (2015)	—	86.50	82.95	82.84	—
Ling et al. (2015)	—	—	—	—	<b>97.78</b>
Lample et al. (2016)	—	90.94	85.75	81.74	—
Ma & Hovy (2016)	—	91.21	—	—	97.55
Ours w/o transfer	94.66	91.20	84.69	85.00	97.55
Ours w/ transfer	<b>95.41</b>	<b>91.26</b>	<b>85.77</b>	<b>85.19</b>	97.55

# Incorporating dictionaries for NER[20][18]

- 数据驱动的方法典型缺乏处理稀有或没有出现的实体，本文在深层网络中加入词典

CCKS-2017 Task2: 临床命名实体识别


本文使用character-level作为嵌入层，同时构造了一个特征向量 $d_i$

特征构造分三种：

1.N-gram feature

总共有8个template，每个template映射到5维上，d, s, t, e, b, 分别表示disease, symptom, treatment, exam, body-part, 即每个字符在这个特征类别上有40维度。

Type	template
2-gram	$x_{i-1}x_i, x_ix_{i+1}$
3-gram	$x_{i-2}x_{i-1}x_i, x_ix_{i+1}x_{i+2}$
4-gram	$x_{i-3}x_{i-2}x_{i-1}x_i, x_ix_{i+1}x_{i+2}x_{i+3}$
5-gram	$x_{i-4}x_{i-3}x_{i-2}x_{i-1}x_i, x_ix_{i+1}x_{i+2}x_{i+3}x_{i+4}$



2.Position-Independent Entity Type feature


对句子X基于词典D进行前向最大匹配，并进行归类，然后将每个字符进行映射，这里其特征表示可以使用one-hot或者特征嵌入矩阵，如下第三行所示

3. Position-Dependent Entity Type feature

这个是有2中切词后的结果来获取的，即该字符是否是实体的开始，中间，结束，或者是单个字符实体，分别用B, I, E, S, 同时可以用one-hot或者特征嵌入矩阵

Character sequence	腹	平	坦	,	未	见	腹	壁	静	脉	曲	张	。
tag sequence	S-b	O	O	O	O	O	B-b	E-b	B-s	I-s	I-s	E-s	O
PIET features	b	None	None	None	None	None	b	b	s	s	s	s	None
PDET features	S-b	None	None	None	None	None	B-b	E-b	B-s	I-s	I-s	E-s	None

这些特征都受词典或上下文的影响，而不受其他句子或统计信息的影响，因此是有别于流行的数据驱动的方法。



提出两种模型如上图所示，3种特征的5种表现形式和2种模型进行组合，结果如下：

		Model-I			Model-II		
		Precision	Recall	F1-Measure	Precision	Recall	F1-Measure
N-gram feature		88.39	88.46	88.43	88.72	88.71	88.71
PIET feature	one-hot encoding	89.53	90.58	90.05	89.38	90.49	89.93
	feature embedding	90.11	90.01	90.56	90.00	90.60	90.30
PDET feature	one-hot encoding	90.51	91.04	90.77	90.22	90.64	90.43
	feature embedding	<b>90.83</b>	<b>91.64</b>	<b>91.24</b>	90.36	91.35	90.85

[Qi Wang et al.2018] Incorporating dictionaries into deep neural networks for the Chinese clinical named entity recognition



# Conclusion

- 经典的三层模型是不会变的
  - Emb representation-info extract-CRF transfor
- 通过各种手段来提高模型的表现
  - 对抗生成网络
  - Attention
  - 加词表，加特征
- 少量标签的学习/加速
  - 迁移学习
  - 主动学习
  - CNN替换LSTM，LSTM替换CRF

## paper:

- [1].[Shaodian Zhang et al.2013] Unsupervised biomedical named entity recognition: Experiments with clinical and biological texts
- [2].[Yukun Chen et al.2015] A study of active learning methods for named entity recognition in clinical text
- [3]. [Zhiheng Huang et al.2015] Bidirectional LSTM-CRF Models for Sequence Tagging
- [4].[Chris Dyer et al.2015] Transition-Based Dependency Parsing with Stack Long Short-Term Memory
- [5].[Guillaume Lample et al.2016] Neural Architectures for Named Entity Recognition
- [6].[Xuezhe Ma et al.2016] End-to-end Sequence Labeling via Bi-directional LSTM-CNNs-CRF
- [7].[Marek Rei et al.2016] Attending to Characters in Neural Sequence Labeling Models
- [8].[Nanyun Peng et al.2016] Improving Named Entity Recognition for Chinese Social Media with Word Segmentation Representation Learning
- [9].[Simon Almgren et al.2016] Named Entity Recognition in Swedish Health Records with Character-Based Deep Bidirectional LSTMs
- [10].[Chuanhai Dong et al.2016] Character-Based LSTM-CRF with Radical-Level Features for Chinese Named Entity Recognition
- [11].[Peters et al.2017] Semi-supervised sequence tagging with bidirectional language models
- [12].[Emma Strubell et al.2017] Fast and Accurate Entity Recognition with Iterated Dilated Convolutions
- [13].[Zhilin Yang et al.2017] TRANSFER LEARNING FOR SEQUENCE TAGGING WITH HIERARCHICAL RECURRENT NETWORKS
- [14].[Maolin Li et al.2017] Proactive Learning for Named Entity Recognition
- [15].[Bill Y.Lin et al.2017] Multi-channel BiLSTM-CRF Model for Emerging Named Entity Recognition in Social Media
- [16].[Yanyao Shen et al.2018] DEEP ACTIVE LEARNING FOR NAMED ENTITY RECOGNITION
- [17].[Yaosheng Yang et al.2018] Adversarial Learning for Chinese NER from Crowd Annotations
- [18].[Zhenghui Wan et al.2018] Label-aware Double Transfer Learning for Cross-Specialty Medical Named Entity Recognition
- [19].[Michihiro Yasunage et al.2018] Robust Multilingual Part-of-Speech Tagging via Adversarial Training
- [20].[Qi Wang et al.2018] Incorporating dictionaries into deep neural networks for the Chinese clinical named entity recognition

**NLP**